# Fondements théoriques du Filtre de Kalman et de l'Algorithme EM pour la Prédiction de Séries Temporelles

Application à la prédiction de cours boursiers

Ce document présente les bases mathématiques du modèle espace-état linéaire Gaussien, du filtre de Kalman (passe avant), du lisseur de Rauch-Tung-Striebel (passe arrière) et de l'algorithme EM pour l'estimation des paramètres — implémentés dans le package `kalman_em`.

3 mars 2026

# Table des matières


**1 Modèle espace-état linéaire Gaussien** **2**
- 1.1 Formulation générale . . . 2
- 1.2 Propriété de Markov . . . 2
- 1.3 Graphe de dépendance . . . 2
- 1.4 Cas particulier : modèle niveau+tendance (Local Linear Trend) . . . 3

**2 Filtre de Kalman (passe avant)** **3**
- 2.1 Objectif . . . 3
- 2.2 Récursion de filtrage . . . 3
- 2.3 Interprétation du gain de Kalman . . . 3
- 2.4 Log-vraisemblance marginale . . . 4

**3 Lisseur de Rauch-Tung-Striebel (passe arrière)** **4**
- 3.1 Objectif . . . 4
- 3.2 Récursion de lissage . . . 4
- 3.3 Covariance décalée d'un pas . . . 4

**4 Algorithme EM pour l'estimation des paramètres** **5**
- 4.1 Principe . . . 5
- 4.2 Décomposition de la log-vraisemblance complète . . . 5
- 4.3 E-step . . . 6
- 4.4 M-step — mises à jour en forme fermée . . . 6
- 4.5 Convergence . . . 6

**5 Algorithme complet EM-Kalman** **7**

**6 Prédiction et intervalles de confiance** **7**
- 6.1 Prédiction un pas en avant . . . 7
- 6.2 Prédiction à horizon $h$ (hors-échantillon) . . . 7

**7 Application et métriques de validation** **7**
- 7.1 Standardisation . . . 7
- 7.2 Métriques de qualité (backtesting) . . . 8
- 7.3 Résultats sur AAPL (2022–2024) . . . 8

# 1 Modèle espace-état linéaire Gaussien

## 1.1 Formulation générale

Un modèle espace-état linéaire Gaussien décrit l'évolution d'un *état latent* $\boldsymbol{x}_t \in \mathbb{R}^d$ observé de manière bruitée via un vecteur d'observations $\boldsymbol{y}_t \in \mathbb{R}^m$.

**Modèle espace-état**

$$\begin{aligned}
\boldsymbol{x}_t &= \boldsymbol{F}\,\boldsymbol{x}_{t-1} + \boldsymbol{w}_t, \quad \boldsymbol{w}_t \sim \mathcal{N}(\boldsymbol{0},\, \boldsymbol{Q}) && \text{(équation d'état)}\\
\boldsymbol{y}_t &= \boldsymbol{H}\,\boldsymbol{x}_t + \boldsymbol{v}_t, \quad \boldsymbol{v}_t \sim \mathcal{N}(\boldsymbol{0},\, \boldsymbol{R}) && \text{(équation d'observation)}\\
\boldsymbol{x}_0 &\sim \mathcal{N}(\boldsymbol{\mu}_0,\, \boldsymbol{\Sigma}_0) && \text{(état initial)}
\end{aligned}$$

Les bruits $\{\boldsymbol{w}_t\}$, $\{\boldsymbol{v}_t\}$ et $\boldsymbol{x}_0$ sont mutuellement indépendants.

TABLE 1 – Paramètres du modèle espace-état

| Symbole | Rôle | Dimensions | Estimé par EM |
|---|---|---|---|
| $\boldsymbol{F}$ | Matrice de transition d'état | $d \times d$ | ✓ |
| $\boldsymbol{H}$ | Matrice d'observation | $m \times d$ | ✓ |
| $\boldsymbol{Q}$ | Covariance du bruit de processus | $d \times d$ | ✓ |
| $\boldsymbol{R}$ | Covariance du bruit d'observation | $m \times m$ | ✓ |
| $\boldsymbol{\mu}_0$ | Moyenne de l'état initial | $d$ | ✓ |
| $\boldsymbol{\Sigma}_0$ | Covariance de l'état initial | $d \times d$ | ✓ |

## 1.2 Propriété de Markov

La propriété de Markov du premier ordre est fondamentale :

$$p(\boldsymbol{x}_t \mid \boldsymbol{x}_{0:t-1},\, \boldsymbol{y}_{1:t-1}) = p(\boldsymbol{x}_t \mid \boldsymbol{x}_{t-1}) = \mathcal{N}(\boldsymbol{x}_t;\, \boldsymbol{F}\boldsymbol{x}_{t-1},\, \boldsymbol{Q}).$$

La distribution jointe se factorise ainsi :

$$p(\boldsymbol{x}_{0:T}, \boldsymbol{y}_{1:T}) = p(\boldsymbol{x}_0) \prod_{t=1}^{T} p(\boldsymbol{y}_t \mid \boldsymbol{x}_t)\, p(\boldsymbol{x}_t \mid \boldsymbol{x}_{t-1}).$$

## 1.3 Graphe de dépendance

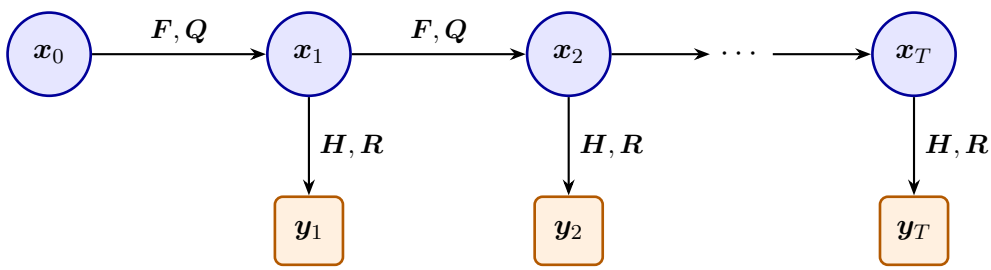

### 1.4 Cas particulier : modèle niveau+tendance (Local Linear Trend)

Pour $d = 2$, $m = 1$ (un seul cours observé), l'état $\boldsymbol{x}_t = (\ell_t,\, s_t)^\top$ combine niveau $\ell_t$ et tendance $s_t$ :

$$\boldsymbol{F} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}, \quad \boldsymbol{H} = \begin{pmatrix} 1 & 0 \end{pmatrix}.$$

L'équation d'état donne :

$$\ell_t = \ell_{t-1} + s_{t-1} + w_t^{(\ell)}, \qquad s_t = s_{t-1} + w_t^{(s)}.$$

Le niveau suit un marchéaléatoire avec drift stochastique, ce qui est conforme au comportement empirique des prix financiers.

## 2 Filtre de Kalman (passe avant)

### 2.1 Objectif

Le filtre de Kalman (Kalman, 1960) calcule de manière récursive les distributions filtrées :

$$p(\boldsymbol{x}_t \mid \boldsymbol{y}_{1:t}) = \mathcal{N}(\boldsymbol{x}_t;\, \hat{\boldsymbol{x}}_{t|t},\, \boldsymbol{P}_{t|t}),$$

et les distributions prédites :

$$p(\boldsymbol{x}_t \mid \boldsymbol{y}_{1:t-1}) = \mathcal{N}(\boldsymbol{x}_t;\, \hat{\boldsymbol{x}}_{t|t-1},\, \boldsymbol{P}_{t|t-1}).$$

### 2.2 Récursion de filtrage

**Filtre de Kalman — passe avant**

**Initialisation** : $\hat{\boldsymbol{x}}_{0|0} = \boldsymbol{\mu}_0, \;\; \boldsymbol{P}_{0|0} = \boldsymbol{\Sigma}_0$.

**Prédiction** (pour $t = 1, \ldots, T$) :

$$\hat{\boldsymbol{x}}_{t|t-1} = \boldsymbol{F}\, \hat{\boldsymbol{x}}_{t-1|t-1} \tag{1}$$

$$\boldsymbol{P}_{t|t-1} = \boldsymbol{F}\, \boldsymbol{P}_{t-1|t-1}\, \boldsymbol{F}^\top + \boldsymbol{Q} \tag{2}$$

**Mise à jour** (pour $t = 1, \ldots, T$) :

$$\boldsymbol{S}_t = \boldsymbol{H}\, \boldsymbol{P}_{t|t-1}\, \boldsymbol{H}^\top + \boldsymbol{R} \qquad \text{(covariance d'innovation)} \tag{3}$$

$$\boldsymbol{K}_t = \boldsymbol{P}_{t|t-1}\, \boldsymbol{H}^\top\, \boldsymbol{S}_t^{-1} \qquad \text{(gain de Kalman)} \tag{4}$$

$$\hat{\boldsymbol{x}}_{t|t} = \hat{\boldsymbol{x}}_{t|t-1} + \boldsymbol{K}_t \underbrace{(\boldsymbol{y}_t - \boldsymbol{H}\, \hat{\boldsymbol{x}}_{t|t-1})}_{\text{innovation } \boldsymbol{\nu}_t} \qquad \text{(état filtré)} \tag{5}$$

$$\boldsymbol{P}_{t|t} = (\boldsymbol{I} - \boldsymbol{K}_t \boldsymbol{H})\, \boldsymbol{P}_{t|t-1}\, (\boldsymbol{I} - \boldsymbol{K}_t \boldsymbol{H})^\top + \boldsymbol{K}_t\, \boldsymbol{R}\, \boldsymbol{K}_t^\top \qquad \text{(forme de Joseph)} \tag{6}$$

### 2.3 Interprétation du gain de Kalman

Le gain $\boldsymbol{K}_t$ pondère la correction apportée par l'innovation $\boldsymbol{\nu}_t$ :

— Si $\boldsymbol{R} \to \boldsymbol{0}$ (observations très fiables) : le filtre corrige fortement vers l'observation.

— Si $\boldsymbol{Q} \to \boldsymbol{0}$ (dynamique très précise) : $\boldsymbol{K}_t \to \boldsymbol{0}$, l'état suit le modèle sans correction.

### 2.4 Log-vraisemblance marginale

$$\log p(\boldsymbol{y}_{1:T}) = \sum_{t=1}^{T} \log p(\boldsymbol{y}_t \mid \boldsymbol{y}_{1:t-1}) = \sum_{t=1}^{T} \left[ -\frac{1}{2}\big(\log|\boldsymbol{S}_t| + \boldsymbol{\nu}_t^\top \boldsymbol{S}_t^{-1}\boldsymbol{\nu}_t + m\log 2\pi\big)\right].$$

Cette quantité est calculée gratuitement lors de la passe avant et sert de critère de convergence pour l'EM.

**Remarque** (Forme de Joseph)**.** *La mise à jour standard* $\boldsymbol{P}_{t|t} = (\boldsymbol{I} - \boldsymbol{K}_t\boldsymbol{H})\boldsymbol{P}_{t|t-1}$ *est algébriquement équivalente mais numériquement instable. La* forme de Joseph

$$\boldsymbol{P}_{t|t} = (\boldsymbol{I} - \boldsymbol{K}_t\boldsymbol{H})\boldsymbol{P}_{t|t-1}(\boldsymbol{I} - \boldsymbol{K}_t\boldsymbol{H})^\top + \boldsymbol{K}_t\boldsymbol{R}\boldsymbol{K}_t^\top$$

*garantit la symétrie et la semi-définie positivité, même en présence d'erreurs d'arrondi.*

## 3 Lisseur de Rauch-Tung-Striebel (passe arrière)

### 3.1 Objectif

Après la passe avant, on a $p(\boldsymbol{x}_t \mid \boldsymbol{y}_{1:t})$ qui n'utilise que les observations *passées*. Le lisseur RTS (Rauch, Tung & Striebel, 1965) exploite *toutes* les observations :

$$p(\boldsymbol{x}_t \mid \boldsymbol{y}_{1:T}) = \mathcal{N}(\boldsymbol{x}_t;\, \hat{\boldsymbol{x}}_{t|T},\, \boldsymbol{P}_{t|T}).$$

### 3.2 Récursion de lissage

**Lisseur RTS — passe arrière**

**Initialisation** : $\hat{\boldsymbol{x}}_{T|T}$, $\boldsymbol{P}_{T|T}$ (résultats du filtre).

**Pour** $t = T-1, T-2, \ldots, 0$ :

$$\boldsymbol{J}_t = \boldsymbol{P}_{t|t}\,\boldsymbol{F}^\top\,\boldsymbol{P}_{t+1|t}^{-1} \qquad \text{(gain de lissage)} \tag{7}$$

$$\hat{\boldsymbol{x}}_{t|T} = \hat{\boldsymbol{x}}_{t|t} + \boldsymbol{J}_t\,(\hat{\boldsymbol{x}}_{t+1|T} - \boldsymbol{F}\,\hat{\boldsymbol{x}}_{t|t}) \qquad \text{(moyenne lissée)} \tag{8}$$

$$\boldsymbol{P}_{t|T} = \boldsymbol{P}_{t|t} + \boldsymbol{J}_t\,(\boldsymbol{P}_{t+1|T} - \boldsymbol{P}_{t+1|t})\,\boldsymbol{J}_t^\top \qquad \text{(covariance lissée)} \tag{9}$$

### 3.3 Covariance décalée d'un pas

Pour l'algorithme EM, on a besoin de l'espérance $\mathbb{E}[\boldsymbol{x}_t\boldsymbol{x}_{t-1}^\top \mid \boldsymbol{y}_{1:T}]$, qui requiert la *covariance croisée lissée* $\boldsymbol{P}_{t,t-1|T}$.

**Proposition 3.1** (Ghahramani & Hinton, 1996)**.**

$$\boldsymbol{P}_{t,t-1|T} = \boldsymbol{P}_{t|T}\,\boldsymbol{J}_{t-1}^\top, \qquad t = 1, \ldots, T-1.$$

La distribution conjointe lissée de $(\boldsymbol{x}_t, \boldsymbol{x}_{t-1})$ est alors :

$$p(\boldsymbol{x}_t, \boldsymbol{x}_{t-1} \mid \boldsymbol{y}_{1:T}) = \mathcal{N}\left(\begin{pmatrix}\hat{\boldsymbol{x}}_{t|T}\\ \hat{\boldsymbol{x}}_{t-1|T}\end{pmatrix}, \begin{pmatrix}\boldsymbol{P}_{t|T} & \boldsymbol{P}_{t,t-1|T}\\ \boldsymbol{P}_{t,t-1|T}^\top & \boldsymbol{P}_{t-1|T}\end{pmatrix}\right).$$

# 4 Algorithme EM pour l'estimation des paramètres

## 4.1 Principe

L'algorithme EM (Dempster, Laird & Rubin, 1977) maximise la log-vraisemblance marginale $\log p(\boldsymbol{y}_{1:T};\, \boldsymbol{\theta})$ en traitant les états latents $\boldsymbol{x}_{0:T}$ comme des données manquantes.

On note $\boldsymbol{\theta} = \{\boldsymbol{F}, \boldsymbol{H}, \boldsymbol{Q}, \boldsymbol{R}, \boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0\}$ l'ensemble des paramètres.

**Fonction $Q$ de l'EM**

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) = \mathbb{E}_{\boldsymbol{x}_{0:T} \mid \boldsymbol{y}_{1:T};\, \boldsymbol{\theta}^{\text{old}}} \big[\log p(\boldsymbol{x}_{0:T}, \boldsymbol{y}_{1:T};\, \boldsymbol{\theta})\big].$$

L'EM alterne entre :

1. **E-step** : calculer $Q$ via filtre de Kalman + lisseur RTS.
2. **M-step** : $\boldsymbol{\theta}^{\text{new}} = \arg\max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}})$.

## 4.2 Décomposition de la log-vraisemblance complète

$$\log p(\boldsymbol{x}_{0:T}, \boldsymbol{y}_{1:T}) = \log p(\boldsymbol{x}_0) + \sum_{t=1}^{T} \log p(\boldsymbol{x}_t \mid \boldsymbol{x}_{t-1}) + \sum_{t=1}^{T} \log p(\boldsymbol{y}_t \mid \boldsymbol{x}_t).$$

En prenant l'espérance sous $p(\boldsymbol{x}_{0:T} \mid \boldsymbol{y}_{1:T};\, \boldsymbol{\theta}^{\text{old}})$ et en développant les densités Gaussiennes :

$$\begin{aligned} Q = &-\tfrac{1}{2}\log|\boldsymbol{\Sigma}_0| - \tfrac{1}{2}\operatorname{tr}\big(\boldsymbol{\Sigma}_0^{-1}\boldsymbol{P}_{0|T}\big) - \tfrac{1}{2}\boldsymbol{\mu}_0^\top\boldsymbol{\Sigma}_0^{-1}\boldsymbol{\mu}_0 + \hat{\boldsymbol{x}}_{0|T}^\top\boldsymbol{\Sigma}_0^{-1}\boldsymbol{\mu}_0 \\ &- \tfrac{T-1}{2}\log|\boldsymbol{Q}| - \tfrac{1}{2}\operatorname{tr}\big(\boldsymbol{Q}^{-1}(\boldsymbol{S}_{11} - \boldsymbol{F}\boldsymbol{S}_{10}^\top - \boldsymbol{S}_{10}\boldsymbol{F}^\top + \boldsymbol{F}\boldsymbol{S}_{00}\boldsymbol{F}^\top)\big) \\ &- \tfrac{T}{2}\log|\boldsymbol{R}| - \tfrac{1}{2}\operatorname{tr}\big(\boldsymbol{R}^{-1}(\boldsymbol{S}_{yy} - \boldsymbol{H}\boldsymbol{S}_{yx}^\top - \boldsymbol{S}_{yx}\boldsymbol{H}^\top + \boldsymbol{H}\boldsymbol{S}_{xx}\boldsymbol{H}^\top)\big) + \text{cte}, \end{aligned} \tag{10}$$

avec les **statistiques suffisantes** :

$$\boldsymbol{S}_{11} = \sum_{t=2}^{T}\big(\boldsymbol{P}_{t|T} + \hat{\boldsymbol{x}}_{t|T}\hat{\boldsymbol{x}}_{t|T}^\top\big) = \sum_{t=2}^{T}\mathbb{E}[\boldsymbol{x}_t\boldsymbol{x}_t^\top \mid \boldsymbol{y}_{1:T}] \tag{11}$$

$$\boldsymbol{S}_{10} = \sum_{t=2}^{T}\big(\boldsymbol{P}_{t,t-1|T} + \hat{\boldsymbol{x}}_{t|T}\hat{\boldsymbol{x}}_{t-1|T}^\top\big) = \sum_{t=2}^{T}\mathbb{E}[\boldsymbol{x}_t\boldsymbol{x}_{t-1}^\top \mid \boldsymbol{y}_{1:T}] \tag{12}$$

$$\boldsymbol{S}_{00} = \sum_{t=1}^{T-1}\big(\boldsymbol{P}_{t|T} + \hat{\boldsymbol{x}}_{t|T}\hat{\boldsymbol{x}}_{t|T}^\top\big) = \sum_{t=1}^{T-1}\mathbb{E}[\boldsymbol{x}_t\boldsymbol{x}_t^\top \mid \boldsymbol{y}_{1:T}] \tag{13}$$

$$\boldsymbol{S}_{yx} = \sum_{t=1}^{T}\boldsymbol{y}_t\,\hat{\boldsymbol{x}}_{t|T}^\top \tag{14}$$

$$\boldsymbol{S}_{yy} = \sum_{t=1}^{T}\boldsymbol{y}_t\boldsymbol{y}_t^\top \tag{15}$$

$$\boldsymbol{S}_{xx} = \sum_{t=1}^{T}\big(\boldsymbol{P}_{t|T} + \hat{\boldsymbol{x}}_{t|T}\hat{\boldsymbol{x}}_{t|T}^\top\big) \tag{16}$$

### 4.3 E-step

**Algorithme E-step**

**Entrée :** $\boldsymbol{y}_{1:T}$, paramètres courants $\boldsymbol{\theta}^{\text{old}}$

**1.** *Passe avant* : filtre de Kalman $\rightarrow$ $\{\hat{\boldsymbol{x}}_{t|t},\, \boldsymbol{P}_{t|t},\, \hat{\boldsymbol{x}}_{t|t-1},\, \boldsymbol{P}_{t|t-1}\}_{t=1}^{T}$

**2.** *Passe arrière* : lisseur RTS $\rightarrow$ $\{\hat{\boldsymbol{x}}_{t|T},\, \boldsymbol{P}_{t|T},\, \boldsymbol{J}_t\}_{t=0}^{T}$

**3.** *Covariances croisées* : $\boldsymbol{P}_{t,t-1|T} = \boldsymbol{P}_{t|T}\boldsymbol{J}_{t-1}^{\top}$ pour $t = 1, \ldots, T-1$

**4.** Calculer les statistiques suffisantes (11)–(16)

### 4.4 M-step — mises à jour en forme fermée

En annulant les dérivées de $Q$ par rapport à chaque paramètre :

**M-step — formules de mise à jour**

$$\boldsymbol{\mu}_0^{\text{new}} = \hat{\boldsymbol{x}}_{0|T} \tag{17}$$

$$\boldsymbol{\Sigma}_0^{\text{new}} = \boldsymbol{P}_{0|T} \tag{18}$$

$$\boldsymbol{F}^{\text{new}} = \boldsymbol{S}_{10}\,\boldsymbol{S}_{00}^{-1} \tag{19}$$

$$\boldsymbol{Q}^{\text{new}} = \frac{1}{T-1}\big(\boldsymbol{S}_{11} - \boldsymbol{F}^{\text{new}}\boldsymbol{S}_{10}^{\top}\big) \tag{20}$$

$$\boldsymbol{H}^{\text{new}} = \boldsymbol{S}_{yx}\,\boldsymbol{S}_{xx}^{-1} \tag{21}$$

$$\boldsymbol{R}^{\text{new}} = \frac{1}{T}\big(\boldsymbol{S}_{yy} - \boldsymbol{H}^{\text{new}}\boldsymbol{S}_{yx}^{\top}\big) \tag{22}$$

*Dérivation de $\boldsymbol{F}^{new}$.* On maximise la partie de $Q$ dépendant de $\boldsymbol{F}$ :

$$Q_F = -\tfrac{1}{2}\operatorname{tr}\big(\boldsymbol{Q}^{-1}(\boldsymbol{S}_{11} - 2\boldsymbol{F}\boldsymbol{S}_{10}^{\top} + \boldsymbol{F}\boldsymbol{S}_{00}\boldsymbol{F}^{\top})\big).$$

En posant $\partial Q_F/\partial \boldsymbol{F} = \boldsymbol{Q}^{-1}(-\boldsymbol{S}_{10}^{\top} + \boldsymbol{F}\boldsymbol{S}_{00}) = \boldsymbol{0}$ :

$$\boldsymbol{F}^{\text{new}} = \boldsymbol{S}_{10}\,\boldsymbol{S}_{00}^{-1}. \qquad \square$$

*Dérivation de $\boldsymbol{Q}^{new}$.* En substituant $\boldsymbol{F}^{\text{new}}$ et en dérivant par rapport à $\boldsymbol{Q}^{-1}$, on utilise $\partial \log|\boldsymbol{Q}|/\partial \boldsymbol{Q}^{-1} = \boldsymbol{Q}$ :

$$(T-1)\boldsymbol{Q} = \boldsymbol{S}_{11} - \boldsymbol{F}^{\text{new}}\boldsymbol{S}_{10}^{\top}. \qquad \square$$

### 4.5 Convergence

**Théorème 4.1** (Monotonie de l'EM)**.** *La suite des log-vraisemblances* $\big\{\log p(\boldsymbol{y}_{1:T};\, \boldsymbol{\theta}^{(k)})\big\}_k$ *est monotone non-décroissante :*

$$\log p\big(\boldsymbol{y}_{1:T};\, \boldsymbol{\theta}^{(k+1)}\big) \;\geq\; \log p\big(\boldsymbol{y}_{1:T};\, \boldsymbol{\theta}^{(k)}\big).$$

*Tout point d'accumulation est un point stationnaire de* $\log p(\boldsymbol{y}_{1:T};\, \boldsymbol{\theta})$.

La preuve repose sur la décomposition :

$$\log p(\boldsymbol{y}_{1:T};\, \boldsymbol{\theta}) = Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{(k)}) - \mathbb{E}_{\boldsymbol{x}_{0:T}|\boldsymbol{y}_{1:T};\, \boldsymbol{\theta}^{(k)}}\big[\log p(\boldsymbol{x}_{0:T} \mid \boldsymbol{y}_{1:T};\, \boldsymbol{\theta})\big].$$

Le second terme est une entropie croisée, bornée supérieurement par l'entropie de $p(\boldsymbol{x}_{0:T} \mid \boldsymbol{y}_{1:T};\, \boldsymbol{\theta}^{(k)})$ (inégalité de Gibbs), ce qui garantit la monotonie.

# 5 Algorithme complet EM-Kalman

**Algorithme EM-Kalman complet**

**Entrée :** $\boldsymbol{y}_{1:T}$, dimension latente $d$, seuil $\varepsilon > 0$

**0.** Initialiser $\boldsymbol{\theta}^{(0)}$ (ex. modèle niveau+tendance, $\boldsymbol{F} = \left[\begin{smallmatrix} 1 & 1 \\ 0 & 1 \end{smallmatrix}\right]$, $\boldsymbol{H} = \left[\begin{smallmatrix} 1 & 0 \end{smallmatrix}\right]$)

**Répéter pour** $k = 0, 1, 2, \ldots$

**E-step :** calculer $\boldsymbol{S}_{11}, \boldsymbol{S}_{10}, \boldsymbol{S}_{00}, \boldsymbol{S}_{yx}, \boldsymbol{S}_{yy}, \boldsymbol{S}_{xx}$ via filtre + lisseur

Calculer $\ell^{(k)} = \log p(\boldsymbol{y}_{1:T};\, \boldsymbol{\theta}^{(k)})$

**Si** $\left|\ell^{(k)} - \ell^{(k-1)}\right| < \varepsilon$ **: arrêter (convergence)**

**M-step :** mettre à jour $\boldsymbol{\theta}^{(k+1)}$ via (17)–(22)

Stabiliser $\boldsymbol{F}$ : si $\rho(\boldsymbol{F}) > 1$, poser $\boldsymbol{F} \leftarrow 0{,}9999 \cdot \boldsymbol{F}/\rho(\boldsymbol{F})$

Régulariser $\boldsymbol{Q}, \boldsymbol{R}, \boldsymbol{\Sigma}_0$ : $A \leftarrow \frac{1}{2}(A + A^\top) + \varepsilon_0 \boldsymbol{I}$ si nécessaire

**Sortie :** $\boldsymbol{\theta}^*$, $\{\ell^{(k)}\}$

**Remarque** (Stabilité numérique)**.** *Deux précautions sont critiques en pratique :*

1. ***Rayon spectral de*** $\boldsymbol{F}$ *: si* $\rho(\boldsymbol{F}) = \max_i |\lambda_i(\boldsymbol{F})| > 1$*, les états latents divergent exponentiellement à chaque pas de temps. La renormalisation* $\boldsymbol{F} \leftarrow \boldsymbol{F}/\rho(\boldsymbol{F})$ *évite ce phénomène.*
2. ***Définie positivité*** *: les matrices* $\boldsymbol{Q}$*,* $\boldsymbol{R}$*,* $\boldsymbol{P}_{t|t}$ *et* $\boldsymbol{P}_{t|t-1}$ *doivent rester définies positives. On ajoute* $\varepsilon_0 \boldsymbol{I}$ *(avec* $\varepsilon_0 = 10^{-8}$*) si la plus petite valeur propre devient négative.*

# 6 Prédiction et intervalles de confiance

## 6.1 Prédiction un pas en avant

La distribution prédictive un pas en avant est :

$$p(\boldsymbol{y}_{t+1} \mid \boldsymbol{y}_{1:t}) = \mathcal{N}\big(\boldsymbol{y}_{t+1};\ \boldsymbol{H}\hat{\boldsymbol{x}}_{t+1|t},\ \boldsymbol{H}\boldsymbol{P}_{t+1|t}\boldsymbol{H}^\top + \boldsymbol{R}\big).$$

L'intervalle de confiance à ≈95% sur le $i$-ième cours est :

$$\hat{y}^{(i)}_{t+1|t} \ \pm\ 2\sqrt{\big[\boldsymbol{H}\boldsymbol{P}_{t+1|t}\boldsymbol{H}^\top + \boldsymbol{R}\big]_{ii}}.$$

## 6.2 Prédiction à horizon $h$ (hors-échantillon)

À partir du dernier état filtré $(\hat{\boldsymbol{x}}_{T|T},\ \boldsymbol{P}_{T|T})$ :

$$\hat{\boldsymbol{x}}_{T+h|T} = \boldsymbol{F}^h\, \hat{\boldsymbol{x}}_{T|T}, \tag{23}$$

$$\boldsymbol{P}_{T+h|T} = \boldsymbol{F}^h \boldsymbol{P}_{T|T} (\boldsymbol{F}^h)^\top + \sum_{j=0}^{h-1} \boldsymbol{F}^j \boldsymbol{Q} (\boldsymbol{F}^j)^\top. \tag{24}$$

L'incertitude croît avec $h$. Pour un processus quasi-intégré ($\rho(\boldsymbol{F}) \approx 1$), la variance grandit linéairement en $h$, reflétant l'imprévisibilité croissante du futur.

# 7 Application et métriques de validation

## 7.1 Standardisation

Avant l'entraînement, les observations sont centrées-réduites : $\tilde{y}_t = (y_t - \bar{y})/\sigma_y$. Cela améliore la stabilité numérique de l'EM et permet une initialisation générique.

### 7.2 Métriques de qualité (backtesting)

Table 2 – Métriques sur les prédictions one-step-ahead

| Métrique | Formule | Interprétation |
|---|---|---|
| MAE | $\frac{1}{T}\sum_t \lvert y_t - \hat{y}_t \rvert$ | Erreur absolue moyenne |
| RMSE | $\sqrt{\frac{1}{T}\sum_t (y_t - \hat{y}_t)^2}$ | Pénalise les grandes erreurs |
| MAPE | $\frac{100}{T}\sum_t \left\lvert \frac{y_t - \hat{y}_t}{y_t} \right\rvert$ | Erreur relative (%) |
| Coverage | $\frac{1}{T}\sum_t \mathbf{1}[y_t \in [\hat{y}_t \pm 2\hat{\sigma}_t]]$ | Calibration ($\approx$ 95% attendu) |

### 7.3 Résultats sur AAPL (2022–2024)

Entraînement sur 602 jours, test sur les 150 derniers :

— **MAE** : 2,53 $ — l'erreur quotidienne représente $\approx$ 1,1% du prix.
— **MAPE** : 1,13 % — erreur relative très faible.
— **Coverage** $\pm 2\sigma$ : 93,3 % — proche de la cible théorique de 95%.

## Références


1. Kalman, R.E. (1960). A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, 82(1), 35–45.
2. Rauch, H.E., Tung, F., & Striebel, C.T. (1965). Maximum likelihood estimates of linear dynamic systems. *AIAA Journal*, 3(8), 1445–1450.
3. Dempster, A.P., Laird, N.M., & Rubin, D.B. (1977). Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society B*, 39(1), 1–38.
4. Shumway, R.H., & Stoffer, D.S. (1982). An approach to time series smoothing and forecasting using the EM algorithm. *Journal of Time Series Analysis*, 3(4), 253–264.
5. Ghahramani, Z., & Hinton, G.E. (1996). Parameter estimation for linear dynamical systems. Technical Report CRG-TR-96-2, University of Toronto.
6. Shumway, R.H., & Stoffer, D.S. (2017). *Time Series Analysis and Its Applications* (4th ed.). Springer.